الترميز الدلالي السياقي: بديل قائم على الأسس اللغوية لتجزئة الوحدات دون الكلمية في نمذجة اللغة

عماد جمعة

الملخص

نقدّم الترميز الدلالي السياقي (CST)، وهو أسلوب ترميز يقسّم النص إلى وحدات دلالية ذات أساس لغوي راسخ بدلاً من شظايا فرعية مشتقّة إحصائيًّا. ينبع هذا النهج من ملاحظة تتعلّق بالصرف العربي الثلاثي: فالجذور والأوزان العربية تشكّل نظامًا جبريًّا طبيعيًّا يكون فيه الجذر × الوزن = المفهوم، ممّا يوفّر بنية دلالية مباشرة في المفردات. نعمّم هذه الرؤية إلى إطار عام قابل للتطبيق على أي لغة. يربط CST الكلمات بمجموعة مغلقة من الحقول الدلالية عبر التجريد الصرفي (lemmatization) والتحليل الصرفي وتحديد الحقل الدلالي، فينتج رموزًا بنيوية مثل `CMP:write:agent` لكلمة "كاتب" أو `REL:causes` لكلمة "لأنّ". في تجارب مضبوطة لتدريب نماذج GPT-2 من الصفر على 100 ألف جملة إنجليزية، نقارن CST بنموذج SentencePiece BPE عند أحجام مفردات متطابقة (8 آلاف و32 ألف) وبنى نموذجية متماثلة تضمن عدد معلمات متساوٍ. باستخدام مقياس البتّات لكل حرف (BPC)، يحقّق CST قيمة 1.13 مقابل 1.75 لـ SentencePiece عند مفردات بحجم 8 آلاف (انخفاض بنسبة 35.5%)، و1.23 مقابل 1.65 عند 32 ألف (انخفاض بنسبة 25.2%). كما ينتج CST تسلسلات رمزية أقصر (22.1 رمز/جملة مقابل 31.7 لـ BPE-8K)، ممّا يؤدي إلى تسريع التدريب بشكل متناسب. تشير هذه النتائج إلى أن ترميز البنية اللغوية مباشرةً في طبقة الترميز يوفّر تحيّزًا استقرائيًّا أقوى لنمذجة اللغة مقارنةً بالتجزئة الفرعية القائمة على التكرار — وهو مبدأ كشفه الصرف العربي أولاً ونعمّمه هنا على الإنجليزية وما بعدها.

1. المقدمة

الترميز هو أول تحويل يُطبَّق على النص قبل أن يصل إلى نموذج لغوي عصبي، ومع ذلك يبقى منفصلاً إلى حدّ بعيد عن النظرية اللغوية. النهج السائد، ترميز أزواج البايت (BPE؛ Sennrich et al., 2016) ومتغيّراته (WordPiece، Unigram)، يبني المفردات عبر دمج تسلسلات الحروف المتكررة تكراريًّا. فالرموز الناتجة ليست سوى نتاجات إحصائية بحتة: تعكس أنماط التواجد المشترك على مستوى السطح في مدوّنة التدريب، لا الوحدات الدلالية أو النحوية. فكلمة مثل "unhappiness" قد تُقسَّم إلى "un" و"happ" و"iness" — أجزاء لا تحمل معنى لغويًّا متّسقًا عبر السياقات.

الدافع لهذا العمل يأتي من مصدر غير متوقَّع: الصرف العربي.

العربية لغة سامية مبنية على نظام الجذر الثلاثي. كل كلمة عربية مشتقّة من جذر ثلاثي الأحرف (وأحيانًا رباعي) عبر تطبيق وزن صرفي. الجذر ك-ت-ب يشفّر الحقل الدلالي للكتابة والتسجيل. تطبيق عشرة أوزان قياسية ينتج عشر كلمات مختلفة:

الوزن	المُعامِل	النتيجة	المعنى
فَاعِل	فاعل	كاتب	الذي يكتب
مَفْعُول	مفعول به	مكتوب	رسالة / شيء مكتوب
مَفْعَلَة	مكان	مكتبة	مكان الكتب
فِعَال	مصدر	كتاب	كتاب واحد
فُعُول	جمع	كُتُب	جمع كتاب
اِسْتِفْعَال	طلب	استكتاب	طلب الكتابة
تَفَاعُل	تبادل	تكاتُب	تبادل الرسائل
مُفَاعَلَة	عملية	مُكاتَبة	المراسلة
فَعَّال	مبالغة	كَتَّاب	كاتب محترف
مُفْعِل	سببي	مُكتِب	الذي يُملي

هذا ليس مجرد وصف لغوي — إنه جبر. الجذر × الوزن = المفهوم. الحقل الدلالي (الكتابة) والدور الصرفي (فاعل، مكان، مفعول به) يتركّبان حتميًّا لينتجا معنًى محدّدًا. والأهم أنّ هذه البنية مشفَّرة مباشرةً في الشكل السطحي للكلمة: يمكن للمحلّل الصرفي استرجاع الجذر والوزن من أي كلمة عربية دون سياق خارجي.

تقودنا هذه الخاصية الجبرية في الصرف العربي إلى طرح التساؤل: **ماذا لو حملت الرموز في مفردات النموذج اللغوي المعلومات البنيوية ذاتها؟** بدلاً من أجزاء فرعية عشوائية، ماذا لو شفَّر كل رمز صراحةً حقله الدلالي ودوره الصرفي؟

ننطلق من هذه الرؤية لبناء إطار عام يتجاوز العربية. فجميع اللغات البشرية تشفّر المعنى تركيبيًّا في بنية الكلمة — عبر اللواحق والسوابق في الإنجليزية، والإلصاق في التركية، وأصناف الأسماء في السواحلية، ونظام الجذر السامي ذاته في العبرية والعربية. هذه تحقّقات سطحية مختلفة لمبدأ مشترك: **الصرف يشفّر العلاقات الدلالية.** يستخلص CST تلك العلاقات ويجعلها صريحة في مفردات الرموز.

نظام الجذر والوزن العربي يجعل هذا المبدأ ظاهرًا بأقصى درجة لأنّ التركيب شفّاف سطحيًّا: يمكن قراءة الجذر والوزن مباشرةً من الهيكل الصامتي وقالب الحركات. الإنجليزية تتطلّب خطوة بحث (تجريد صرفي + كشف اللواحق) لاسترجاع المعلومات ذاتها. لكنّ المعلومات موجودة في كلتا اللغتين — العربية ببساطة تجعل من الصعب تفويتها.

يقدّم هذا البحث المساهمات التالية:

1. نتتبّع الأصل المفاهيمي لـ CST إلى الصرف الثلاثي العربي، مبيّنين كيف يُعمَّم تركيب الجذر × الوزن إلى مبدأ ترميز شامل.
2. نصف مسار معالجة CST، وهو نظام ترميز من سبع مراحل ينتج رموزًا مصنَّفة ومشروحة لغويًّا للإنجليزية.
3. نقدّم مقارنة مضبوطة مع SentencePiece BPE عند أحجام مفردات وعدد معلمات متطابقة، عازلين استراتيجية الترميز كمتغيّر وحيد.
4. نسجّل انخفاضًا بنسبة 35.5% في BPC عند مفردات 8 آلاف و25.2% عند 32 ألف، مبرهنين أنّ البنية اللغوية في الترميز تحسّن كفاءة نمذجة اللغة.

5. نحلّل خصائص CST العابرة للغات، مبيّنين أنّ فضاء الرموز الدلالية محايد لغويّا وأنّ العربية واللغات الغنية صرفيّا مستفيدة طبيعيًّا.

2. الأعمال السابقة

ترميز الوحدات الفرعية. يبقى BPE (Sennrich et al., 2016) ومتغيّراته — WordPiece (Schuster & Nakajima, 2012) وUnigram (Kudo, 2018) وSentencePiece (Kudo & Richardson, 2018) — الأساليب المعيارية للترميز في النماذج اللغوية العصبية. تُحسّن هذه الأساليب ضغط مدوّنة التدريب دون مراعاة البنية اللغوية. أشارت أعمال حديثة إلى قيود: بيّن Bostrom & Durrett (2020) أنّ تجزئة BPE غالبًا لا تتوافق مع الحدود الصرفية، وأظهر Rust et al. (2021) أنّ جودة المرمّز تتدهور للغات الممثَّلة تمثيلاً ناقصًا في النماذج متعددة اللغات.

الترميز الصرفي. تشمل محاولات إدماج الصرف في الترميز نظام Morfessor (Creutz & Lagus, 2007) الذي يجزّئ الكلمات إلى صيغ صرفية باستخدام الحد الأدنى لطول الوصف، وعمل Ataman & Federico (2018) الذين طبّقوا التجزئة الصرفية المُشرَف عليها في الترجمة الآلية العصبية. تحسّن هذه الأساليب معالجة اللغات الغنية صرفيًّا لكنّها لا تُسند محتوًى دلاليًّا للرموز. تشمل الأعمال الخاصة بالعربية CAMeLBERT (Inoue et al., 2021) وAraBERT (Antoun et al., 2020) اللذين يطبّقان معالجة صرفية مسبقة قبل تدريب على طراز BERT لكنّهما يحتفظان بمفردات الوحدات الفرعية في طبقة مدخل النموذج.

الصرف السامي كحساب. دُرست البنية الجبرية للصرف السامي القائم على الجذر والوزن رسميًّا منذ McCarthy (1981) الذي قدّم علم الأصوات التطريزي لنمذجة الطبيعة غير التسلسلية لتشكيل الكلمات في العربية والعبرية. طوّر Beesley & Karttunen (2003) نماذج محوّلات الحالة المنتهية للصرف السامي، ووسّع Kiraz (2001) هذا إلى تمثيلات متعددة الطبقات. تعامل هذه الأعمال الصرف كمشكلة تحليل — استرجاع الجذور والأوزان من الأشكال السطحية. يعكس CST هذا: يستخدم البنية المسترجَعة كمفردات توليدية للنماذج العصبية.

التمثيلات الدلالية في معالجة اللغات الطبيعية. تقترح نظرية الحقل الدلالي (Trier, 1931) ودلالات الإطار (Fillmore, 1982) أنّ معاني الكلمات تنتظم في حقول مهيكلة. يوفّر FrameNet (Baker et al., 1998) وWordNet (Miller, 1995) مسردًا حاسوبيًّا للعلاقات الدلالية. إلا أنّ هذه الموارد لم تُطبَّق على مستوى الترميز — بل تُستخدم عادةً في مراحل لاحقة لمهام مثل التصنيف الدلالي للأدوار.

موقع CST. يسدّ CST الفجوة بين الترميز الصرفي والتمثيل الدلالي. يستمدّ من البنية الجبرية للصرف العربي كأساس مفاهيمي، ويمدّد تحليل الجذر-الوزن إلى الإنجليزية عبر التجريد الصرفي وكشف اللواحق، ويشفّر النتيجة مباشرةً في مفردات الرموز التي يتدرّب عليها النموذج اللغوي. على خلاف المجزّئات الصرفية، يربط CST الرموز بحقول دلالية. وعلى خلاف قواعد البيانات الدلالية، يعمل CST على مستوى الترميز. الجديد الجوهري هو أنّ البنية الدلالية ليست شرحًا في مرحلة لاحقة — بل هي المفردات ذاتها.

3. من الجبر العربي إلى الترميز الشامل

قبل وصف مسار معالجة CST، نوضّح المسار المفاهيمي من الصرف العربي إلى الإطار العام. هذا الأصل ليس عرضيًّا — قرارات التصميم في CST تعكس بنية الصرف العربي مباشرةً.

3.1 العربية كمخطّط أوّلي

في العربية، كل كلمة ذات محتوى هي حاصل ضرب مكوّنين متعامدين:

- **الجذر (الجِذر):** مجموعة من ثلاثة (وأحيانًا أربعة) صوامت تشفّر حقلاً دلاليًّا. الجذر ك-ت-ب يغطّي حقل الكتابة والتسجيل بأكمله، والجذر ع-ل-م يغطّي حقل المعرفة والتعلّم، والجذر ج-م-ع يغطّي الجمع والتجميع.
- **الوزن (الوَزن):** قالب صرفي يحدّد الدور النحوي للكلمة. وزن فَاعِل ينتج الفاعل النشط لأي جذر، ومَفْعَلَة ينتج المكان المرتبط بأي جذر، ومَفْعُول ينتج المفعول به لأي جذر.

تركيب الجذر × الوزن حتمي ومنتج: بمعلومية أي جذر وأي وزن، يكون معنى الكلمة الناتجة متوقَّعًا. هذا هو الجبر. كتب × فاعل = كاتب؛ علم × مفعلة = مدرسة؛ جمع × استفعال = اجتماع.

نوع الرمز `CMP:field:role` في CST هو ترميز مباشر لهذا الجبر. `CMP:write:agent` هو التمثيل الحاسوبي لـ كتب × فاعل. `CMP:know:place` هو التمثيل الحاسوبي لـ علم × مفعلة. نظام الصرف العربي، الذي دُرس وصُقل على مدى أربعة عشر قرنًا من البحث اللغوي، يوفّر الأساس المفاهيمي. يجعله CST قابلاً للحوسبة ومستقلاً عن اللغة.

3.2 التعميم على الإنجليزية

لا تمتلك الإنجليزية نظام جذور على الطراز العربي، لكنّها تمتلك بنية صرفية تشفّر العلاقات ذاتها بشفافية أقل:

العربية (صريحة)	الإنجليزية (قابلة للاسترجاع)	رمز CST
كاتب (جذر: كتب + وزن: فاعل)	writer (جذر: write + لاحقة: -er)	`CMP:write:agent`
مكتبة (جذر: كتب + وزن: مفعلة)	library (حقل دلالي: write + دور: place)	`CMP:write:place`
مكتوب (جذر: كتب + وزن: مفعول)	document (حقل دلالي: write + دور: instance)	`CMP:write:instance`
معلّم (جذر: علم + وزن: مفعّل)	teacher (جذر: teach + لاحقة: -er + سببي دلالي)	`CMP:know:causer`

في العربية، الاستخلاص صرفي: يُقرأ الجذر والوزن من الشكل السطحي. في الإنجليزية، يتطلّب الاستخلاص تجريدًا صرفيًّا (writer ← write) وكشف لواحق (-er → agent) وبحث في الحقل الدلالي (write → field:write). المخرَج هو الرمز البنيوي ذاته. الطريق العربي أكثر مباشرة، والطريق الإنجليزي يتطلّب معالجة أكثر. كلاهما يصل إلى المفردات ذاتها.

3.3 الحقول الدلالية الشاملة

الحقول الدلالية في CST — write، know، move، create، send، think، gather — ليست تصنيفات إنجليزية. إنّها بدائيات دلالية شاملة تظهر في جميع اللغات البشرية لأنّها تصف أنشطة إنسانية جوهرية. وثّق McCarthy (1981) وأعمال لاحقة في التصنيف اللغوي أنّ الحقول الدلالية كالحركة والإدراك والإبداع والتواصل شاملة عبر عائلات لغوية غير مترابطة.

هذه الشمولية هي مفتاح إمكانات CST العابرة للغات. عندما يُربط "الباحث" بالعربية و"researcher" بالإنجليزية كلاهما بـ `CMP:science:agent`، يتعلّم نموذج يتدرّب على اللغتين في فضاء الرموز ذاته تمثيلاً موحّدًا للمفهوم. رموز LIT — كلمات الوظيفة والأعلام والأشكال السطحية غير المحلَّلة — تحمل معلومات خاصة باللغة. الرموز الدلالية تحمل معلومات شاملة. نموذج متعدد اللغات مبني على CST يشارك نواته الدلالية بالكامل عبر اللغات؛ فقط طبقة LIT تتغيّر.

نُشير، بوصفها ملاحظة لا ادّعاءً تصميميًا، إلى أنّ هذه الخاصية تحمل تشابهًا بنيويًا مع ما سعت إليه مشاريع اللغات الكونية المصطنعة — كالإسبرانتو والإنترلينغوا — بصورة مقصودة. والفارق هو في المنشأ: تلك المشاريع فرضت مفردات مشتركة عبر تصميم صريح ومتعمّد. أمّا في CST، فإنّ الطبقة الدلالية المشتركة لم تكن نتيجةً مقصودة؛ بل نشأت كأثرٍ مترتّب على تأسيس الرموز في بدائيات صرفية ودلالية تُشير الدراسات اللسانية التيبولوجية إلى أنّها حاضرة بصورة مستقلة في جميع اللغات البشرية. وما إذا كان هذا التوافق العابر للغات الناشئ يُفضي إلى فوائد قابلة للقياس في النمذجة متعددة اللغات يبقى سؤالاً تجريبيًا مفتوحًا نَكِلُه إلى أعمال مستقبلية.

---

4. المنهج

4.1 نظرة عامة

يعمل CST عبر مسار معالجة من سبع مراحل يحوّل النص الخام إلى تسلسل من الرموز المصنَّفة. كل رمز ينتمي إلى واحد من ستة أنواع:

النوع	الصيغة	مثال	الوصف
CMP	`CMP:field:role`	`CMP:write:agent`	مركَّب: حقل دلالي + دور صرفي
ROOT	`ROOT:field`	`ROOT:move`	حقل دلالي، بدون اشتقاق صرفي
REL	`REL:relation`	`REL:causes`	علاقة نحوية أو منطقية
STR	`STR:structure`	`STR:negation`	علامة بنيوية على مستوى الجملة
LIT	`LIT:surface`	`LIT:the`	رمز حرفي (كلمات وظيفية، كيانات، كلمات غير محلَّلة)
SPECIAL	`[PAD]` ، `[UNK]`	`[UNK]`	حشو ومجهول

رمز CMP يشفّر الجبر العربي مباشرةً: الحقل = المجال الدلالي للجذر، الدور = معامل الوزن. ROOT يشفّر حقلاً دلاليًّا بدون دور صرفي قابل للاسترجاع. REL وSTR يشفّران البنية على مستوى الجملة. LIT هو الخيار الاحتياطي للكلمات التي لا تشارك في الجبر الدلالي.

4.2 مراحل خط الأنابيب

المرحلة 1: التطبيع. يُحوَّل النص المُدخَل إلى أحرف صغيرة، وتُستبدَل علامات الاقتباس الذكية بمكافئاتها في ASCII، وتُطبَّع المسافات البيضاء. يضمن هذا معالجة متّسقة في المراحل اللاحقة دون فقدان المحتوى الدلالي.

المرحلة 2: كشف البنية. تفحص مجموعة من التعبيرات النمطية الجملة الكاملة بحثًا عن أنماط بنيوية قبل المعالجة على مستوى الكلمة. تُكتشَف ستة أنواع بنيوية:

- `STR:question` — علامة استفهام نهائية
- `STR:negation` — علامات نفي (*not*، *never*، *cannot*، إلخ)
- `STR:condition` — علامات شرط (*if*، *unless*، *whenever*، إلخ)
- `STR:future` — علامات زمن مستقبل (*will*، *shall*، *going to*)

- `STR:past` — علامات زمن ماضٍ (*was*، *were*، *had*، *did*)
- `STR:emphasis` — علامة تعجّب نهائية

تُضاف رموز البنية في بداية تسلسل الرموز، مزوّدةً النموذج بإطار على مستوى الجملة قبل معالجة الكلمات الفردية. يحاكي هذا وظيفة الحروف النحوية العربية (هل للاستفهام، لا للنفي، سـ للاستقبال) التي تعمل على مستوى الجملة.

المرحلة 3: تقسيم الكلمات. يُقسَّم النص المطبَّع عند حدود المسافات وعلامات الترقيم. تُرشَّح أجزاء الاختصارات (*'m*، *'d*، *'ve*، *'ll*، *'re*، *n't*، *s*) وعلامات الترقيم المنفردة، إذ يُلتقَط محتواها الدلالي بواسطة كشف البنية أو يكون ضئيلاً.

المرحلة 4: التعرّف على الكيانات المسمّاة. تحدّد مكتبة NLP المسمّاة compromise.js الكيانات المسمّاة (أشخاص، أماكن، مؤسسات) في النص الأصلي. تتجاوز الكيانات المعرَّفة التحليل الصرفي وتحديد الحقل الدلالي، وتُصدَر مباشرةً كرموز `LIT:surface` للحفاظ على الأعلام.

المرحلة 5: التجريد الصرفي. تُجرَّد كل كلمة صرفيًّا باستخدام compromise.js، الذي يردّ الأفعال إلى صيغة المصدر والأسماء إلى المفرد. تُخزَّن النتائج مؤقتًا في خريطة دائمة لتجنّب استدعاءات NLP المكرّرة؛ في تشغيل 100 ألف جملة، يُصادَف نحو 78 ألف شكل كلمة فريد ويُخزَّن مؤقتًا.

المرحلة 6: التحليل الصرفي. يُقارَن الشكل السطحي والجذر المجرَّد لكشف الإلصاق:

- كشف السوابق (9 سوابق): تُطابَق سوابق مثل *non*-، *out*-، *co*-، *over*-، *mis*-، *pre*-، *dis*-، *re*-، *un*- عند حدود الكلمات، منتجةً أدوارًا مثل `before`، `repeat`، `negate`. يمنع حدّ أدنى لطول الجذع (3 أحرف) الإيجابيات الكاذبة.
- كشف اللواحق (25 لاحقة): عندما يختلف الشكل السطحي عن الجذر المجرَّد في النهاية، يُطابَق الفرق مع لواحق معروفة. تُطابَق اللواحق وفق مبدأ الأطول أولاً، وتنتج أدوارًا مثل *-tion*، *-ment*، (*-er*، *-or*، *-ist*) `instance`، `agent` (*-s*، *-es*) `plural`، (*-ed*) `past`، (*-able*، *-ible*) `possible`، (*-ness*، *-ity*) `state`، (*ing*)، وغيرها.

الربط من اللاحقة إلى الدور يحاكي نظام الأوزان العربي: حيث تستخدم العربية فاعل لتمييز فاعل أي فعل، تستخدم الإنجليزية *-er*. الأدوار ذاتها — causer، instance، place، patient، agent — متطابقة في النظامين، لأنّها تعكس علاقات دلالية شاملة وليست اصطلاحات خاصة بلغة.

المرحلة 7: إصدار الرموز. تُحلَّل كل كلمة إلى رمز عبر تسلسل من الأولويات:

1. إذا كانت الكلمة كيانًا مسمًّى معرَّفًا → `LIT:surface`
2. إذا كانت الكلمة تسلسل أرقام → `ROOT:size`
3. إذا ظهرت الكلمة في خريطة العلاقات (~245 مدخل تغطّي حروف الجر، الروابط، الأفعال الناقصة، المحدّدات، الظروف) → `REL:relation`
4. إذا كانت الكلمة وظيفية (~95 مدخل: أدوات التعريف، الضمائر، الأفعال المساعدة) → `LIT:surface`
5. يُبحَث عن الجذر الصرفي في قاموس الحقول الدلالية (~2,400 ربط جذر-حقل يغطّي ~45 حقلاً شاملاً). تزيد آلية استرجاع الحرف الصامت (مثلاً *writ* → *write*) والتجريد المتداخل للواحق من التغطية. إذا وُجد حقل:
   - مع دور صرفي → `CMP:field:role` (مثلاً `CMP:write:agent` → *writer*)
   - بدون دور → `ROOT:field` (مثلاً `ROOT:write` → *write*)
6. الخيار الاحتياطي → `LIT:surface`

4.3 مسرد الحقول الدلالية

يربط قاموس الحقول الدلالية الجذور المجرَّدة بواحد من نحو 45 حقلاً شاملاً. أمثلة تمثيلية:

الحقل	مجموعة الجذور
`think`	consider، think، reason، judge، analyze
`move`	go، travel، arrive، depart، return
`create`	make، build، create، produce، design
`know`	know، learn، understand، study، teach
`send`	send، transmit، dispatch، deliver
`write`	write، record، document، publish
`see`	see، observe، watch، notice، perceive

صُمِّمت هذه الحقول لتكون شاملة: الحقول ذاتها تنطبق عبر اللغات، لأنّ البدائيات الدلالية مثل *move* و*think* و*create* و*know* تظهر في جميع اللغات البشرية. هذا ليس افتراضًا — إنّه نتيجة التصنيف اللغوي المقارن (Fillmore, 1982؛ Miller, 1995). الجذور العربية المستخدمة في محرّك الجبر العربي الأصلي (كتب لـ write، علم لـ know، رسل لـ send، جمع لـ gather) تُربط مباشرةً بهذه الحقول. أسماء الحقول هي تسميات محايدة لغويًّا لمجالات دلالية حدّدتها العربية بنيويًّا.

4.4 تقييد حجم المفردات

في شكله غير المقيَّد، ينتج CST نحو 846 رمزًا دلاليًّا (CMP، ROOT، REL، STR، SPECIAL) وعددًا متغيّرًا من رموز LIT للكلمات غير المغطّاة بقاموس الحقول الدلالية. لإجراء مقارنة مضبوطة مع خطّ أساس ثابت المفردات، نقيّد مفردات CST إلى حجم مستهدَف V عبر:

1. الاحتفاظ بجميع الرموز الدلالية (~846)
2. حجز خانات لـ PAD وUNK
3. ملء الخانات المتبقية $V - 848$ بأكثر رموز LIT تكرارًا من مدوّنة التدريب
4. ربط جميع رموز LIT المتبقية بـ UNK

عند مفردات 8 آلاف، ينتج هذا معدّل UNK بنسبة 5.6% (كلمات نادرة تظهر أقل من 10 مرات). عند مفردات 32 ألف، ينخفض معدّل UNK إلى 1.6%.

---

5. الإعداد التجريبي

جميع الشفرات ونصوص التدريب والورقة البحثية متاحة علنًّا على **https://github.com/emadjumaah/cst**.

5.1 مجموعة البيانات

نستخدم 99,963 جملة إنجليزية من مجموعة بيانات Hugging Face) `agentlans/high-quality-english-sentences`)، مصدرها ويكيبيديا وتغطّي مجالات متنوّعة تشمل العلوم والتاريخ والجغرافيا والتكنولوجيا والسِّيَر. توفّر المجموعة تغطية معجمية واسعة دون تحيّز مجالي.

5.2 تكوينات المرمِّز

نقارن أربعة تكوينات مرمِّز في زوجين متطابقين:

التكوين	المرمِّز	حجم المفردات	الوصف
CST-8K	CST (مقيَّد)	8,000	846 دلالي + 7,152 LIT متكرر + PAD + UNK
SPM-8K	SentencePiece BPE	8,000	BPE معياري مدرَّب على المدوّنة ذاتها
CST-32K	CST (مقيَّد)	32,000	846 دلالي + 31,152 LIT + PAD + UNK
SPM-32K	SentencePiece BPE	32,000	BPE معياري مدرَّب على المدوّنة ذاتها

تُدرَّب نماذج SentencePiece على الجمل الـ 99,963 ذاتها باستخدام إعدادات BPE الافتراضية. يضمن هذا أنّ كلا المرمِّزين يريان بيانات تدريب متطابقة.

5.3 بنية النموذج

تستخدم جميع النماذج بنية GPT-2 (Radford et al., 2019) كما نُفِّذت في Hugging Face Transformers:

المعامل الفائق	القيمة
بُعد التضمين	256
الطبقات	6
رؤوس الانتباه	4
الطول الأقصى للتسلسل	128
معدّل التعلّم	3×10^{-4}
حجم الدُّفعة	32
المحسّن	AdamW (تناقص الأوزان 0.01)
المجدوِل	تلدين جيب التمام
الحقب	3
نسبة التحقّق	10%

ضمن كل زوج متطابق المفردات، يمتلك كلا النموذجين **عدد معلمات متطابقًا**: 6.8 مليون عند مفردات 8 آلاف (2.0 مليون تضمين + 4.7 مليون محوّل) و13.0 مليون عند 32 ألف (8.2 مليون تضمين + 4.7 مليون محوّل). الفرق الوحيد بين النموذجين المزدوجين هو استراتيجية الترميز.

5.4 مقياس التقييم

نستخدم **البتّات لكل حرف (BPC)** كمقياس تقييم أساسي:

$$\mathrm{BPC} = \frac{\sum_i \mathrm{NLL}_i}{C \cdot \ln 2}$$

حيث NLL_i هي سالب اللوغاريتم الاحتمالي لكل رمز مجموعةً على جميع رموز التحقّق، وC هو العدد الإجمالي للحروف في نصّ التحقّق الأصلي.

يُطبّع BPC الفروقات في طول التسلسل الرمزي وحجم المفردات. على خلاف الحيرة (perplexity) التي تعمل في فضاء الرموز ولا يمكن مقارنتها عبر مرمّزات بمفردات مختلفة، يقيس BPC عدد البتّات التي يحتاجها النموذج لترميز كل حرف من النصّ الأصلي. الأقل أفضل.

نسجّل أيضًا حيرة كل رمز ومتوسط الرموز لكل جملة للاكتمال، لكنّنا نؤكّد أنّ هذه المقاييس غير قابلة للمقارنة مباشرةً عبر المرمّزات.

---

6. النتائج

6.1 النتائج الرئيسية

المقياس	CST-8K	SPM-8K	CST-32K	SPM-32K
المفردات	8,000	8,000	32,000	32,000
المعلمات	6.8م	6.8م	13.0م	13.0م
متوسط الرموز/جملة	22.1	31.7	22.1	26.6
حيرة التحقّق	113.0	163.9	172.8	302.5
BPC التحقّق	**1.13**	**1.75**	**1.23**	**1.65**
انخفاض BPC		**35.5%**		**25.2%**

عند مفردات 8 آلاف، يحقّق CST قيمة BPC تبلغ 1.13 مقابل 1.75 لـ SentencePiece — انخفاض بنسبة 35.5%. عند مفردات 32 ألف، يحقّق CST قيمة 1.23 مقابل 1.65 — انخفاض بنسبة 25.2%. كلتا المقارنتين تستخدمان بنى متطابقة بعدد معلمات متطابق.

6.2 طول التسلسل الرمزي

ينتج CST تسلسلات أقصر باستمرار: 22.1 رمز لكل جملة بغضّ النظر عن حدّ المفردات، مقابل 31.7 (SPM-8K) و26.6 (SPM-32K). يعكس ثبات طول تسلسل CST عبر أحجام المفردات حقيقة أنّ الرموز الدلالية لا تتأثّر بتقييد المفردات — فقط رموز LIT النادرة تُربط بـ UNK، ممّا لا يغيّر عدد الرموز.

للتسلسلات الأقصر بنسبة 30% فائدة حاسوبية مباشرة: يُكمل CST-8K كل حقبة تدريب في 102 ثانية مقابل 159 ثانية لـ SPM-8K على وحدة GPU من طراز NVIDIA T4، وهو تحسّن في الإنتاجية بمقدار 1.56× بسبب تقليل طول التسلسل في حساب الانتباه الذاتي.

6.3 تأثير تركيب المفردات

نتيجة غير متوقّعة هي أنّ CST-8K (6.8 BPC، 1.13 مليون معلمة) يتفوّق على CST-32K (13.0 BPC، 1.23 مليون معلمة) رغم امتلاكه معلمات ومفردات أقل. نعزو هذا إلى تركيز المفردات: عند 8 آلاف، تحتوي المفردات فقط على كلمات عالية التكرار إلى جانب الرموز الدلالية، ممّا يقلّل تناثر فضاء التضمين. معدّل UNK البالغ 5.6% عند 8 آلاف يعمل فعليًّا كمنظّم للنموذج، مجبرًا إيّاه على الاعتماد على البنية الدلالية بدلاً من حفظ الأشكال السطحية النادرة.

يتناقض هذا مع SentencePiece، حيث تتفوّق مفردات 32 ألف (1.65 BPC) على مفردات 8 آلاف (1.75 BPC)، متّبعةً النمط المتوقَّع لمرمّزات الوحدات الفرعية حيث تقلّل المفردات الأكبر دقّة التجزئة.

6.4 ديناميكيات التدريب

المقياس	CST-8K	SPM-8K
BPC الحقبة 1	1.17	1.91
BPC الحقبة 2	1.14	1.78
BPC الحقبة 3	1.13	1.75
التحسّن بين الحقب	-0.02، -0.01	-0.13، -0.03

يتقارب CST أسرع ويبدأ من خسارة أولية أقل. في الحقبة 1، يحقّق CST-8K بالفعل 1.17 BPC، وهو مستوى لا يصله SPM-8K حتى بعد 3 حقب. يُظهر SPM-8K تحسّنات أكبر بين الحقب، ممّا يشير إلى أنّه قد يستمر في تضييق الفجوة مع مزيد من التدريب، لكنّ الميزة الأولية للترميز البنيوي كبيرة.

---

7. المناقشة

7.1 لماذا يساعد الترميز الدلالي؟

نحدّد ثلاث آليات يحسّن CST من خلالها نمذجة اللغة:

ضغط التسلسل. يمثّل CST كل كلمة ذات محتوى برمز واحد (ROOT أو CMP)، بينما قد يقسّمها BPE إلى 2-4 أجزاء فرعية. التسلسلات الأقصر تعني أنّ الانتباه الذاتي للنموذج يعمل على تمثيل أكثر إيجازًا للمعلومات ذاتها، ممّا يقلّل المسافة بين الرموز المترابطة دلاليًّا.

التحيّز الاستقرائي البنيوي. تشفّر رموز CST صراحةً الحقول الدلالية والأدوار الصرفية. الرمز `CMP:write:agent` يشير إلى أنّ هذه الكلمة تنتمي إلى مجموعة *write* الدلالية وتعمل كـ *agent*. لا يحتاج النموذج لتعلّم هذه العلاقات من إحصاءات التواجد المشترك الخامّ — فهي مقدَّمة مباشرةً في تمثيل المدخل. هذا هو التحقّق الحاسوبي للجبر العربي: يتلقّى النموذج الجذر × الوزن كمدخل مهيكل بدلاً من استرجاعه ضمنيًّا من البيانات.

التعميم على مستوى الحقل. الكلمات المربوطة بالحقل الدلالي ذاته تتشارك بادئة رمز. "Writer" و"writing" و"written" و"wrote" كلّها تنتج رموزًا تبدأ بـ `write`، مختلفةً فقط في الدور. يتيح هذا للنموذج التعميم عبر التنوّعات الصرفية دون حاجة لرؤية كل شكل سطحي في التدريب. في العربية، هذا التعميم تلقائي: أي كلمة مشتقّة من كتب تتشارك هوية الجذر في التمثيل الصرفي. يجعل CST التعميم المكافئ متاحًا لنماذج مدرَّبة على الإنجليزية.

7.2 العربية كخطوة طبيعية تالية

التجارب في هذا البحث أُجريت على الإنجليزية. العربية هي، بمعنى دقيق، اللغة التي يتطلّب CST لأجلها أقل عمل إضافي وحيث تكون مزاياه أكبر.

في العربية، تُستبدَل مرحلة التحليل الصرفي في مسار معالجة CST باستخلاص مباشر للجذر والوزن. أدوات مثل Farasa (Abdelali et al., 2016) وCAMeL Tools (Obeid et al., 2020) تستخلص الجذور والأوزان العربية من الأشكال السطحية بدقّة عالية. حيث يكتشف المرمّز الإنجليزي اللاحقة *-er* في "writer" ويبحث عن "write" في قاموس الحقول الدلالية، يقرأ المرمّز العربي "كاتب"، ويحدّد الجذر كتب والوزن فاعل، ويُصدر `CMP:write:agent` مباشرةً — الرمز ذاته.

هذا يعني أنّ مرمّز CST عربيًّا ينتج نسبة أعلى من رموز CMP (معدّل LIT أقل) مقارنةً بالمرمّز الإنجليزي، لأنّ انتظام الصرف العربي يجعل كلمات أكثر قابلة للتحليل. معدّل الرموز البنيوية البالغ 66.1% المحقَّق على ويكيبيديا الإنجليزية هو حدّ أدنى لما ستحقّقه العربية.

علاوةً على ذلك، لأنّ الرموز الدلالية متطابقة عبر اللغات، فإنّ نموذجًا مدرَّبًا مسبقًا على رموز CST إنجليزية ثمّ مضبوطًا بدقّة على رموز CST عربية يتشارك مفردات مشتركة لكل المحتوى الدلالي. النقل العابر للغات لا يتطلّب محاذاة: `CMP:write:agent` يعني الشيء ذاته سواء جاءت جملة التدريب من الإنجليزية أو العربية.

7.3 الخصائص العابرة للغات

خاصية معمارية جوهرية لـ CST هي أنّ مفرداته الدلالية (~846 رمزًا) محدودة ومحايدة لغويًّا. عدد الحقول الدلالية الشاملة محدود. مع نمو حجم المدوّنة، ينخفض معدّل رموز LIT الجديدة دون خطّي، لأنّ معظم الكلمات ذات المحتوى تُربط في النهاية بحقول موجودة مع توسّع القاموس.

في المقابل، تتوسّع مفردات BPE خطّيًّا مع التنوّع اللغوي. مرمّز BPE متعدد اللغات يجب أن يخصّص خانات مفردات لتسلسلات حروف خاصة بكل لغة. الحقول الدلالية لـ CST محايدة لغويًّا: *write* في الإنجليزية، و*écrire* في الفرنسية، وكتب في العربية، وكَ في اليابانية كلّها تُربط بالحقل ذاته. لهذا نتيجة مباشرة: يمكن للغتين التشارك في نموذج واحد إذا تشاركتا فضاء الرموز الدلالية لـ CST — وهو ما يتحقّق بالتصميم. جملة إنجليزية وترجمتها العربية تنتجان تسلسلات رموز متداخلة:

- الإنجليزية: `[CMP:know:causer] [REL:to] [CMP:send:past] [CMP:write:agent]`
- العربية: `[CMP:know:causer] [REL:to] [CMP:send:past] [CMP:write:agent]`

يتعلّم النموذج في فضاء المفاهيم. اللغات سطوح مختلفة فوق البنية الدلالية ذاتها.

إضافة لغة جديدة إلى CST تتطلّب: (1) محلّلاً صرفيًّا لتلك اللغة، (2) مدخلات خاصة باللغة في خرائط العلاقات والبنية (~30 مدخلاً جديدًا)، (3) رموز LIT خاصة باللغة. الرموز الدلالية الـ ~846 تُنقَل دون تغيير. للغات الغنية صرفيًّا — العربية والعبرية والتركية والفنلندية — حيث يكون نظام الجذر-الوزن أو الإلصاق صريحًا في شكل الكلمة، تدعم الأدوات الحالية الخطوة (1) جيّدًا. الجبر الدلالي الذي كشفته العربية هو الأساس؛ وCST هو التعميم.

7.4 معدّل UNK كتنظيم ضمني

جدير بالملاحظة أنّ CST-8K يتفوّق على CST-32K رغم أملكه معلمات ومفردات أقل. فمعدّل UNK البالغ 5.6% عند 8 آلاف يعمل كنوع من إسقاط عشوائي على مستوى المدخل، مانعًا النموذج من حفظ الأشكال السطحية النادرة ومجبرًا إيّاه على الاعتماد على البنية الدلالية للرموز المتبقية. يحاكي هذا نتائج أدبيات الإسقاط (Srivastava et al., 2014) حيث يمكن للضوضاء على مستوى المدخل تحسين التعميم عبر منع التكيّف المشترك. في حالة CST، "الضوضاء" ذات أساس لغوي: فقط الأشكال السطحية النادرة منخفضة التكرار تُطوى إلى UNK، بينما تبقى البنية الدلالية سليمة. يشير هذا إلى أنّ التقييد الحادّ للمفردات قد يكون تقنية مفيدة لـ CST، خاصةً في بيئات الموارد المحدودة حيث يجعل شحّ البيانات تضمين الرموز النادرة غير منتج.

7.5 القيود

تغطية الحقول الدلالية. يغطّي تنفيذنا نحو 2,400 ربط جذر-حقل. عند مفردات 8 آلاف مع التقييد، 5.6% من حالات الرموز تقع في UNK. توسيع القاموس الدلالي سيحسّن التغطية، لكن حتى عند المستويات الحالية يحقّق النموذج نتائج قوية.

الاعتماد على أدوات NLP. يعتمد CST على compromise.js للتجريد الصرفي والتعرّف على الكيانات المسمّاة. جودة هذه المكوّنات تؤثّر مباشرةً في جودة الترميز. أخطاء التجريد الصرفي تنتشر إلى تحديد حقل خاطئ. استبدال واجهة NLP الخلفية بأداة أكثر دقّة سيحسّن النتائج على الأرجح.

تقييم لغة واحدة. نقيّم على الإنجليزية فقط. في حين أنّ إطار الحقول الدلالية شامل نظريًّا، وأنّ الأصل العربي للإطار يشير إلى قابلية تطبيق قوية على اللغات السامية، فإنّ التحقّق التجريبي على لغات غنية صرفيًّا (العربية، التركية، الفنلندية) ولغات متنوّعة تصنيفيًّا (الصينية، اليابانية) ضروري.

تجارب صغيرة الحجم. تستخدم تجاربنا 100 ألف جملة ونماذج حتى 13 مليون معلمة. يبقى سؤالاً مفتوحًا ما إذا كانت مزايا CST تستمرّ عند حجم النماذج اللغوية الحديثة. نلاحظ نتائج متّسقة عبر حجمَي المفردات (35.5% عند 8 آلاف، 25.2% عند 32 ألف)، ممّا يشير إلى أنّ التأثير ليس معتمدًا على حجم المفردات، وإن كان التحقّق عند حجم أكبر يبقى عملاً مستقبليًّا.

تقييم المهام اللاحقة. نقيّم على نمذجة اللغة (BPC) فقط. التقييم على مهام لاحقة مثل تصنيف المشاعر والإجابة عن الأسئلة والترجمة الآلية سيوفّر صورة أكمل عن فائدة CST.

---

8. العمل المستقبلي

CST عربي. الأصل المفاهيمي لهذا العمل هو الصرف العربي. تنفيذ CST للعربية باستخدام Farasa أو CAMeL Tools لاستخلاص الجذر والوزن سيتحقّق من الإطار على اللغة التي حفّزته، ومن المتوقَّع أن يحقّق تغطية رموز بنيوية أعلى من الإنجليزية. تحقّق تجريبي — تدريب نموذج واحد على رموز CST إنجليزية وعربية متداخلة — سيختبر ما إذا كان الفضاء الدلالي المشترك يتيح نقلاً حقيقيًّا عابرًا للغات دون بيانات متوازية.

CST متعدد اللغات. بعد العربية، يلائم CST طبيعيًّا العبرية (نظام الجذر السامي) والتركية (الصرف الإلصاقي بلواحق أدوار صريحة) والفنلندية (صرف أسماء مُعرَب بالحالات). قاموس دلالي متعدد اللغات يربط جذور لغات متعددة بمجموعة الحقول ذاتها سيتيح مرمّزًا مشتركًا بمفردات مدمجة محايدة لغويًّا.

تقييم المهام اللاحقة. التقييم على التصنيف (SST-2) والإجابة عن الأسئلة (SQuAD) والاستدلال اللغوي الطبيعي (MNLI) ومعايير الترجمة الآلية سيثبت ما إذا كانت تحسينات BPC تترجم إلى مكاسب على مستوى المهام.

تجارب التوسّع. تدريب نماذج أكبر (100 مليون+ معلمة) على مدوّنات أكبر (مليون+ جملة) سيوضّح ما إذا كانت مزايا CST تستمرّ أو تتناقص عند الحجم الكبير.

الترميز الهجين. بدلاً من الرجوع إلى رموز LIT للكلمات غير المحلَّلة، يمكن لنهج هجين استخدام تجزئة الوحدات الفرعية كخيار احتياطي، جامعًا بين دقّة CST الدلالية ومتانة BPE للكلمات خارج المفردات.

حقول دلالية قابلة للتعلّم. قاموس الحقول الحالي مُنظَّم يدويًّا. طريقة تلقائية لاستنباط الحقول الدلالية من البيانات التوزيعية — مثلاً عبر تجميع تضمينات الكلمات وربط المجموعات بتسميات حقول — ستوسّع CST إلى إعدادات المفردات المفتوحة.

9. الخاتمة

قدّمنا الترميز الدلالي السياقي، وهو أسلوب ترميز قائم على أسس لغوية راسخة يستمدّ أساسه المفاهيمي من البنية الجبرية للصرف الثلاثي العربي. تركيب الجذر × الوزن في العربية — نظام صُقل على مدى أربعة عشر قرنًا من الاستخدام اللغوي — يشفّر الحقل الدلالي والدور الصرفي مباشرةً في بنية الكلمة. يعمّم CST هذا المبدأ إلى إطار شامل، مسترجعًا المعلومات البنيوية ذاتها من الإنجليزية عبر التجريد الصرفي وكشف اللواحق، ومشفّرًا إيّاها كرموز دلالية مصنَّفة يمكن لأي نموذج لغوي التدرّب عليها.

في تجارب مضبوطة ببنى نموذجية وعدد معلمات متطابقة، يقلّل CST البتّات لكل حرف بنسبة 35.5% عند مفردات 8 آلاف و25.2% عند 32 ألف مقارنةً بـ SentencePiece BPE. كما ينتج CST تسلسلات رمزية أقصر بنسبة 30%، ممّا يسرّع التدريب.

تبرهن هذه النتائج أنّ ترميز البنية اللغوية مباشرةً في طبقة الترميز يوفّر تحيّزًا استقرائيًّا ذا مغزى لنمذجة اللغة. النهج بسيط التنفيذ، ولا يتطلّب تدريبًا إضافيًّا يتجاوز بناء القاموس، وينتج رموزًا قابلة للتفسير. امتداده الأكثر طبيعية هو العربية — اللغة التي جعل جبرها الصرفي المبدأ مرئيًّا — ومنها إلى أي لغة ذات بنية صرفية قابلة للاسترجاع.

كان نظام الجذر والوزن العربي نظامًا جبريًّا متكاملاً قبل أن تظهر النماذج اللغوية العصبية بقرون. CST هو، بمعنى ما، ملاحظة أنّ هذا الجبر كان مرمّزًا ينتظر أن يُستخدَم.

المراجع

Abdelali, A., Darwish, K., Durrani, N., & Mubarak, H. (2016). Farasa: A fast and furious segmenter for Arabic. *Proceedings of NAACL-HLT: Demonstrations*.

Antoun, W., Baly, F., & Hajj, H. (2020). AraBERT: Transformer-based model for Arabic language understanding. *Proceedings of the LREC Workshop on Language Models and Their Applications*.

Ataman, D., & Federico, M. (2018). An evaluation of two vocabulary reduction methods for neural machine translation. *Proceedings of the 13th Conference of the Association for Machine Translation in the Americas*.

Baker, C. F., Fillmore, C. J., & Lowe, J. B. (1998). The Berkeley FrameNet project. *Proceedings of COLING-ACL*.

Beesley, K. R., & Karttunen, L. (2003). *Finite State Morphology*. CSLI Publications.

Bostrom, K., & Durrett, G. (2020). Byte pair encoding is suboptimal for language model pretraining. .*Findings of EMNLP*

Creutz, M., & Lagus, K. (2007). Unsupervised models for morpheme segmentation and morphology .learning. *ACM Transactions on Speech and Language Processing*, 4(1)

.Fillmore, C. J. (1982). Frame semantics. *Linguistics in the Morning Calm*

Inoue, G., Alhafni, B., Baimukan, N., Bouamor, H., & Habash, N. (2021). The interplay of variant, size, .and task type in Arabic pre-trained language models. *Proceedings of ARABICNLP*

Kiraz, G. A. (2001). *Computational Nonlinear Morphology*: *With Emphasis on Semitic Languages*. Cambridge .University Press

Kudo, T. (2018). Subword regularization: Improving neural network translation models with multiple .subword candidates. *Proceedings of ACL*

Kudo, T., & Richardson, J. (2018). SentencePiece: A simple and language independent subword .tokenizer and detokenizer for neural text processing. *Proceedings of EMNLP*: *System Demonstrations*

McCarthy, J. J. (1981). A prosodic theory of nonconcatenative morphology. *Linguistic Inquiry*, 12(3), .373–418

.Miller, G. A. (1995). WordNet: A lexical database for English. *Communications of the ACM*, 38(11)

Obeid, O., Zalmout, N., Khalifa, S., Taji, D., Oudah, M., Alhafni, B., Inoue, G., Eryani, F., Erdmann, A., & Habash, N. (2020). CAMeL Tools: An open source Python toolkit for Arabic natural language .processing. *Proceedings of LREC*

Radford, A., Wu, J., Child, R., Luan, D., Amodei, D., & Sutskever, I. (2019). Language models are .unsupervised multitask learners. *OpenAI Technical Report*

Rust, P., Pfeiffer, J., Vulić, I., Ruder, S., & Gurevych, I. (2021). How good is your tokenizer? On the .monolingual performance of multilingual language models. *Proceedings of ACL*

Schuster, M., & Nakajima, K. (2012). Japanese and Korean voice search. *IEEE International Conference .on Acoustics, Speech, and Signal Processing*

Sennrich, R., Haddow, B., & Birch, A. (2016). Neural machine translation of rare words with subword .units. *Proceedings of ACL*

Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(1), 1929– .1958

.Trier, J. (1931). *Der deutsche Wortschatz im Sinnbezirk des Verstandes*. Heidelberg: Winter

الملحق أ: أمثلة الترميز

المُدخَل: "The researchers discovered that rewriting the algorithm significantly improved computational efficiency."

الرمز	النوع	الشرح
`STR:past`	STR	كُشف زمن ماضٍ ("discovered")
`LIT:the`	LIT	كلمة وظيفية
`CMP:science:agent`	CMP	"researchers" ← حقل *science*، دور *agent*
`CMP:know:past`	CMP	"discovered" ← حقل *know*، دور *past*
`REL:that`	REL	أداة ربط
`CMP:write:repeat`	CMP	"rewriting" ← حقل *write*، دور *repeat*
`LIT:the`	LIT	كلمة وظيفية
`ROOT:think`	ROOT	"algorithm" ← حقل *think*
`CMP:quality:manner`	CMP	"significantly" ← حقل *quality*، دور *manner*
`CMP:fix:past`	CMP	"improved" ← حقل *fix*، دور *past*
`CMP:think:quality`	CMP	"computational" ← حقل *think*، دور *quality*
`CMP:work:state`	CMP	"efficiency" ← حقل *work*، دور *state*

تجزئة BPE-8K:

`_re writ ing _the _algorithm _significant ly _improv ed _comput ational _effic iency`

(17 رمزًا)

CST: 12 رمزًا، **BPE-8K:** 17 رمزًا. يلتقط CST العلاقات الدلالية التي تفقدها أجزاء BPE.

مثال عابر للغات: المكافئ العربي — "اكتشف الباحثون أن إعادة كتابة الخوارزمية حسّنت الكفاءة الحسابية بشكل ملحوظ" — ينتج تسلسل CST متداخلاً إلى حدّ بعيد، لأنّ الصرف العربي يقدّم تحليل الجذر-الوزن مباشرةً:

الرمز	النوع	المصدر العربي
`STR:past`	STR	زمن ماضٍ على مستوى الجملة
`CMP:know:past`	CMP	اكتشف — جذر ك-ش-ف (know)، وزن افتعل (past)
`CMP:science:agent`	CMP	الباحثون — جذر ب-ح-ث (science)، وزن فاعل (agent)
`REL:that`	REL	أن
`CMP:write:repeat`	CMP	إعادة كتابة — جذر ك-ت-ب (write)، إعادة (repeat)
`ROOT:think`	ROOT	الخوارزمية — حقل *think*
`CMP:fix:past`	CMP	حسّنت — جذر ح-س-ن (fix)، وزن فعّل (past)
`CMP:work:state`	CMP	الكفاءة — حقل *work*، دور *state*
`CMP:think:quality`	CMP	الحسابية — حقل *think*، دور *quality*

الرموز الدلالية متطابقة. فقط كلمات الوظيفة الخاصة باللغة تختلف. هذه هي الخاصية العابرة للغات لـ CST مجسَّدة: الصرف العربي ينتج مباشرةً تمثيل الرمز ذاته الذي تحتاج الإنجليزية مسار معالجة كاملاً لاسترجاعه.

الملحق ب: مسرد الحقول الدلالية (مقتطف)

الحقل	جذور تمثيلية	المجال الدلالي
`think`	consider، reason، analyze، compute، calculate	الإدراك
`move`	go، travel، arrive، depart، migrate، flow	الحركة
`create`	make، build، produce، generate، design، invent	الإبداع
`know`	learn، understand، study، teach، educate	المعرفة
`write`	record، document، note، publish، inscribe	التعبير الكتابي
`send`	transmit، dispatch، deliver، forward، mail	النقل
`see`	observe، watch، notice، perceive، detect	الإدراك البصري
`speak`	say، tell، announce، declare، communicate	التعبير الشفهي
`feel`	sense، experience، suffer، enjoy	الانفعال
`govern`	rule، regulate، administer، legislate	السلطة
`trade`	buy، sell، exchange، import، export	التجارة
`fight`	attack، defend، resist، conquer، invade	الصراع
`dwell`	live، reside، inhabit، settle، shelter	السكن
`health`	heal، cure، treat، diagnose، infect	الطب
`nature`	grow، bloom، evolve، decay، erode	العمليات الطبيعية

هذه الحقول مصدرها قاموس الجذور في محرّك الجبر العربي، الذي نظّم أكثر من 820 جذرًا عربيًّا في مجالات دلالية. تبيّن لاحقًا أنّ الحقول شاملة — المجالات الدلالية ذاتها تظهر في الإنجليزية، والجذور العربية ذاتها التي ترسو كل مجال تُربط بمجموعات الجذور الإنجليزية ذاتها.

الملحق ج: قابلية إعادة الإنتاج التجريبي

جميع الشفرات وخطوط أنابيب البيانات ونصوص التدريب متاحة في مستودع المشروع. يمكن إعادة إنتاج التجربة كما يلي:

1. **إعداد البيانات:** 99,963 جملة من (Hugging Face) `agentlans/high-quality-english-sentences`، مُحمَّلة عبر صيغة Parquet.
2. **ترميز CST:** مسار معالجة بـ TypeScript باستخدام compromise.js v14.14.3 للتجريد الصرفي والتعرّف على الكيانات المسمّاة.
3. **تدريب SentencePiece:** مكتبة v0.2.1 `sentencepiece` Python، وضع BPE، مدرَّب على الجمل الـ 99,963 ذاتها.
4. **تقييد المفردات:** مفردات CST مقيَّدة إلى 8 آلاف و32 ألف بالاحتفاظ بجميع الرموز الدلالية وأكثر رموز LIT تكرارًا.

5. **تدريب النموذج:** GPT-2 عبر Hugging Face Transformers، مدرّب على Google Colab بوحدة GPU من طراز NVIDIA T4.

6. **التقييم:** BPC محسوب كمجموع NLL التحقّق (بالنات) مقسومًا على إجمالي حروف التحقّق مقسومًا على ln(2).

الشفرة الكاملة — المرمّز (TypeScript) ونصوص التدريب (Python) وأدوات تقييد المفردات وهذه الورقة — متاحة على **https://github.com/emadjumaah/cst**. قاموس الحقول الدلالية ومحرّك الجبر العربي الذي حفّز هذا العمل متاحان على https://emadjumaah.github.io/aae/.